ENGINEERING · EVIDENCE · EVALUATION · DESIGN

MGAR V3.1 完整技术报告

事件驱动持续研发Agent：技术选型、架构、真实评测、失败修复与业务产品设计

版本：2026-11-06-public-v1。日期按Asia/Shanghai。整理基线：`2155556cb1c1288f08b5b3abebe55f2a7112253d`；E/F执行代码冻结于`ff6353d`，三臂v6冻结于`c5ca75c`。本轮只整理文档和GitHub页面，没有新增模型调用、业务Issue/评论/PR或部署。

项目首页 · 文档导航 · PDF · 独立HTML · 事实与来源索引

阅读目录

1. 项目目标与当前范围
2. 技术选型与锁定版本
3. 架构与权威边界
4. 持续任务、路由与输入版本
5. 跨源调查、检索与证据判定
6. 代码修复、审批与交付
7. 预算、恢复与独立部署
8. 实验设计与全部主要结果
9. 困难、错误与对应解决过程
10. 仅完成设计的两项P0
11. 复现、验证及源码导航
12. 剩余限制与工程经验
13. 主要证据

1. 项目目标与当前范围

MGAR V3.1探索如何让大模型参与持续研发任务：接收GitHub工单或本地请求，读取知识、数据库和代码，保留来源证据，提出受限补丁，并在审批后可靠交付。核心目标包括任务连续性、授权边界、执行一致性、可追溯结果及故障恢复。

DeepSeek官方API承担推理，项目实现应用层Agent运行时。基础模型未训练或微调；检索使用预训练中文词向量及独立学习的轻量重排参数。系统中的多Agent是有界协作结构，包含单Run内专家和实验协调器，具体边界由不同评测分别说明。

代码当前具有调查、持续工单、受限Router、跨源工具、纯函数修复、审批发布、监控与恢复能力。三个层面的状态需要分别读取：

层面	已有成果	结论范围
工程实现	R0–R6核心及注册验收；最新E/F专项98项通过	不同历史快照测试有重叠，不能相加成当前全量成绩
真实实验	R1评论、R4跨源对照、R5 Draft PR恢复、R6三臂及D/E/F对照	使用真实模型/工具和自有合成资料，保留失败
业务产品	“研巡”电商工单闭环、统一业务结果判定	两项P0设计完成，运行代码/表/API尚未实施

当前已通过的R6发布门禁适用于用户批准的独立Linux/systemd虚拟机。P0业务设计不改变旧R6状态。用户已指定其余P1/P2改进不开展，因此本报告记录这些边界，不启动新的改造或实验。

2. 技术选型与锁定版本

以下Python版本来自当前uv.lock；基础服务与实际解释器版本来自已有验证记录。它们是可核对的项目版本，不表示本轮重新安装或运行了全部组件。

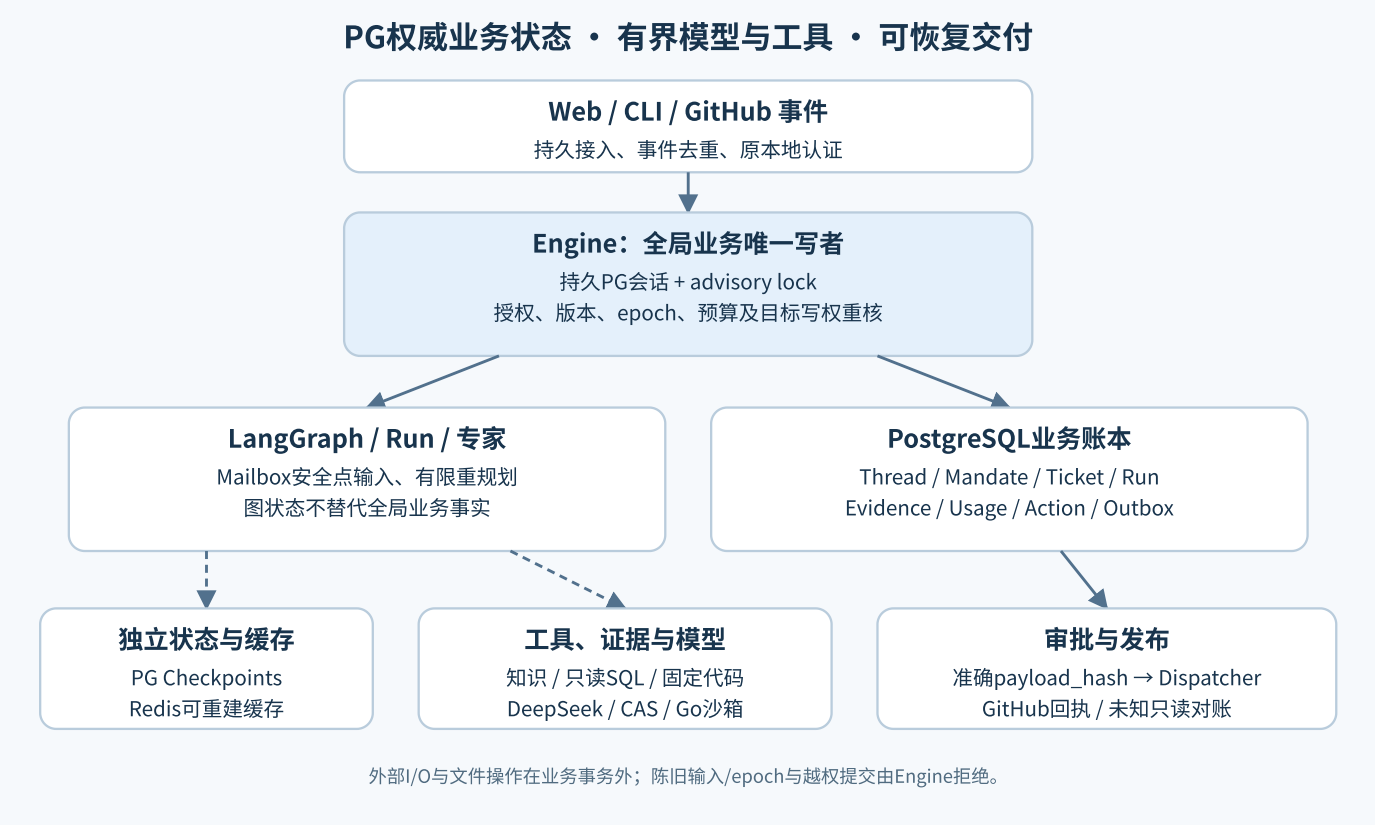
技术	项目版本/配置	用途与选择理由
Python	3.12系列，已验证3.12.14	异步API、模型/工具生态、严格类型与评测脚本
FastAPI / Uvicorn	0.162.0 / 0.54.0	本地API、任务工作台后端、SSE、CLI共用Engine
Pydantic	2.14.2	严格请求/响应契约、禁止额外字段、授权profile哈希
LangChain / LangGraph	1.4.7 / 1.2.19	模型适配、Run内状态图、专家分支与恢复
PostgreSQL Checkpoint	3.2.0	官方PostgresSaver保存图状态，与业务账本分开
PostgreSQL / pgvector	已验证16.12 / 0.8.1	权威业务状态、短事务、约束、向量检索；产品17个显式迁移
psycopg	3.3.6	持久Engine会话、事务与池；checkpoint另用官方连接机制
Redis	客户端7.4.1，服务端7.4.7	可重建缓存、限流与来源缓存观察，不承载业务权威
MCP	Python SDK 1.30.0，GitHub服务端v2.0.3	受限知识/数据/代码工具，读写凭据和工具组隔离
DeepSeek	官方chat/completions；已冻结实验模型deepseek-flash	结构化调查、专家综合、受限函数体或路由候选选择
SQLGlot	27.14.0	解析并白名单检查受限PostgreSQL SELECT语法
中文检索	jieba 0.42.1、BM25、pgvector、300维词向量、RRF、成对线性重排	本地混合召回与排序，参数/资料版本可冻结
文档与HTTP	pypdf 6.21.4、httpx 0.28.1	PDF文本提取、受控HTTP调用及回执留存
Docker / Go	固定沙箱镜像及可信AST工具	编译执行受限补丁，隔离候选代码与宿主凭据

技术	项目版本/配置	用途与选择理由
Linux / systemd / QEMU	独立Debian12/Linux6.1测试VM，QEMU TCG	服务用户、部署、整虚拟节点重启及备份恢复
工程工具	uv.lock、pytest 9.2.0、ruff 0.17.3、mypy 1.20.2	可重复依赖、注册验收、类型与风格检查

技术选择的核心是明确每个组件的责任。PG维护业务事实，LangGraph维护Run内部控制流，Redis缓存可失效信息，模型提出内容或候选，可信代码校验范围和事实。原生HTML/CSS/JavaScript工作台通过API/SSE展示原业务状态，本项目没有依赖新的前端框架来承担状态权威。

依赖依据：pyproject.toml、uv.lock、验证版本、容器配置、GitHub MCP锁、检索模型锁。

3. 架构与权威边界



系统架构

3.1 业务对象分离

对象	含义	设计作用
Thread	GitHub Issue等外部会话	接收事件和维护消息序号；不等于一次执行
Mandate	actor、project、repository、工具/操作范围及模式	将用户意图与可用权限固化
Ticket	一份工作项	管理开放/结束和Run归属
Run	具体执行尝试	绑定图版本、输入版本、epoch、结果和预算
Assignment	Run内有限专家任务	限制角色、输入和可读来源，不给予全局调度权
Action	准备对外执行的准确动作	固定目标、payload_hash、输入版本、期限与写权
Outbox	已批准动作的派发记录	记录发送、回执、未知和对账进展

这种分离使同一Issue的后续消息不必创建完全无关的任务，也使调查权限、补丁权限和发布权限可以分别校验。一个Thread最多一个active primary，observer/context链接不继承对其他Run的写权限。

3.2 单写者与事务

Engine的持久PG会话持有advisory lock，所有全局业务与实验元数据写入使用该连接和短事务。连接丢失后原执行不再拥有写入权；不能另开连接绕过锁。checkpoint属于图状态，官方PostgresSaver可以使用独立连接/schema，它不推进全局业务事实。

网络请求、文档解析、嵌入、来源文件/CAS读写、Docker编译都在业务事务之外完成。提交时重新核对输入revision、execution epoch、scope及目标写权。先写不可变Artifact再提交数据库引用；失败可以留下未引用文件，不能留下已发送但未登记的本地业务意图。

PG约束还负责唯一事件、Mailbox序号、一个active primary及稳定预算记录。工程接受以真实PG为基础，没有用SQLite替代并发与事务验收。

3.3 三层状态

图checkpoint、业务账本、远端GitHub对象各自有提交边界。图恢复先读取Engine事实，不能凭checkpoint重复推进副作用；远端写与本地事务无法原子提交，使用Outbox和未知结果对账收束不确定性。项目不宣称跨系统exactly-once。

设计依据：ADR0001、R2、R5。

4. 持续任务、路由与输入版本

4.1 Mailbox与安全点

CLI/Web/GitHub事件经过统一入口持久化。相同source/external_event_id及相同payload返回原回执；同键异内容拒绝。已订阅消息直达primary Mailbox，冷事件进入有限路由队列。

Run在调查/验证/工具节点后的安全点执行intake：先保存不可变输入快照，再由replan确认消费游标。快照、checkpoint和确认不是一个分布式原子事务，因此节点重入必须幂等。原始question保留，追加内容进入新输入版本。新输入会使未发送的旧提案失效，新提案需要新hash审批。

R2边界包括：最多三个用户输入版本（初始加两次replan）、Mailbox 64条/64KiB、快照64KiB、过期输入明确阻塞。长只读任务有持久job和lease，在线程执行后由Engine登记结果；API与控制循环继续响应。

4.2 epoch与控制

暂停/取消先持久化并提高execution epoch；旧Worker的迟到结果在提交处被拒绝。恢复沿用原授权、预算和已知结果，不撤销已经发出的远端写。取消后的晚到回执只记录事实，不能恢复任务或自动发布。

4.3 两种路由实现的范围

产品R3 Router处理受限冷启动、澄清、控制与任务关联，输出候选提案，不持有调查/发布工具。Engine按批次冻结的Thread revision、Run epoch、Mandate、policy和上下文重核。已有订阅与显式命令走确定性路径。

D/E/F是独立实验协调准入适配器。v1让模型自由产生action和Run UUID，暴露初始错误；v2改为可信代码从公开PG快照生成合法候选，模型只回选event_key/candidate_id。目标留在服务端绑定，并在同一SQL事务中检查Issue、Run、epoch、revision和当前actor后ingest。

v2的固定负载每个事件只有一个合法候选，效果主要来自软件约束。实验适配器提示与产品冷启动Router不同，不能用这份实验替代产品复杂语义路由评测。

依据：R3 ADR、候选契约ADR、协调源码。

5. 跨源调查、检索与证据判定

5.1 知识库与检索

文档先保存原始Artifact和入库任务，解析/嵌入在业务事务外执行；全部成功后用CAS检查发布active snapshot，失败不切换索引。查询先按project/repository/actor/ACL/snapshot过滤，再做BM25、向量召回、RRF融合和学习重排。

本地向量由zh_core_web_md 3.8.0的中文预训练词向量取平均，形成300维L2归一化向量。重排为独立训练并冻结的pairwise linear模型。训练/测试问题及参数摘要留档；fixture向量的协议检查与真实本地检索效果分列。

Redis命中只返回可重建引用，读取时重新检查当前权限。来源撤权影响旧快照引用和缓存。摘要记忆必须经用户确认准确hash，不能把任何模型总结直接写成可信事实。

5.2 受限SQL与真实代码

SQL只连接注册的本地只读角色/schema，限制到orders单表与允许的SELECT AST节点；禁止越权表/函数、写操作和不受控语法，限制行数、字节、参数和执行时间。实际结果保存列类型OID、单元格值、查询和观察回执。

GitHub证据固定到commit、tree、blob及字节hash。MCP只读/发布工具组分离，工具能力由Engine针对Run/epoch/task/role签发，模型不能自报身份。真实MCP返回结构按协议解析，不能假定总是纯文本。

5.3 事实、计算与独立判定

机械Verifier核对实际读取、本Run/assignment归属、当前ACL、来源hash、定位、引用原文及typed SQL cell。数值任务在实际读取行上用Decimal计算，并用SQL count/sum/min交叉检查。稳定业务数据进入模型；含时间戳的审计回执保存在私有CAS，避免同一事实因回执变化产生假冲突。

R6输出协议使用公开字段契约、实际来源quote_id、受限函数体和末端检查；已知格式错误允许既定预算内有限反馈，未知费用/网络结果停止。专家已知结构错误可审计后丢弃摘要，主Agent继续使用原始证据；不能丢弃权限错误或未知调用。

引用有效、字段正确、业务答案正确和自然语言因果解释充分是不同指标。v2 E的一项结果即为来源子串有效、Run成功，但没有满足完整行契约而被独立Oracle判FAIL。P0统一结果设计专门处理这类状态歧义，当前尚未实施。

依据：R4设计、跨源真实报告、数值复现。

6. 代码修复、审批与交付



补丁审批与交付边界

6.1 有界补丁生成

当前允许修复一个获准文件中的Go纯函数体。固定source_ref、完整基础tree、文件blob和workspace hash；不允许修改测试/构建文件、imports、符号链接、任意路径或越界调用。

早期模型直接输出unified diff，容易出现hunk行数错误、上下文/定位错误。R5先做仅重算hunk行数的确定性恢复，原始失败保留。R6后续协议让模型返回function_body，由可信固定函数框架机械渲染diff；业务逻辑仍需测试，不会因为diff可解析就判正确。

6.2 沙箱和测试

可信Go辅助程序在宿主解析AST，不执行候选。候选测试在固定镜像运行，非root UID65532、断网、只读根、无凭据/宿主挂载/socket、cap-drop、禁止提权，并限制512MiB内存、96个PID及超时/输出。实际超时由调用参数确定，入口上限45秒，默认30秒。

公开测试与独立Oracle生成的28个隐藏Go子案例分别记录，隐藏测试源码/期望不发给模型。测试回执绑定镜像、完整候选文件、workspace/tree和日志hash。编辑补丁会取消旧提案、增加输入版本并重新测试。

6.3 准确审批与持久发布

Action固定目标、完整payload、diff/tree/test hashes、执行epoch、输入revision和有效期。用户批准准确payload_hash，Dispatcher才领取Outbox。过期审批保持拒绝；同hash显式续签有独立审阅记录，不能修改旧Action到期时间来伪造有效。

Draft PR拆成branch、commit、pull_request三个持久步骤，各自登记请求hash与回执。回执丢失后进入outcome_unknown，通过只读核对仓库、唯一分支、父commit、完整tree/blob、正文、Draft状态与head/base恢复。部分对象成功不自动删除，也不自动续发未确认写入。

真实Draft PR #2完成接收后SIGKILL与只读恢复，保持Draft、未合并。这证明受限任务的交付恢复闭环，不是任意仓库自动修复成绩。

依据：R5真实报告、原修复边界、显式续签。

7. 预算、恢复与独立部署

7.1 授权与费用

环境开关表示配置，不构成付费或发布许可。LiveProfile固定模型、目标、来源、上下文、输出和调用/费用上限；授权须匹配profile/manifest hash、actor、范围及到期。调用前预占，返回有效usage后结算；响应或计费未知则保留预占并停止。

评测使用独立共享预算，子任务仍受各自上限。仓库累计费用跨project/profile聚合，包含历史Router调用；旧组不清零、未用次数不自动转移。当前代码继续执行更严格的US$2仓库硬上限。

冻结峰值费用采用每次输入/输出token与对应价格向上取整。例：E/F v2以输入0.3、输出1.2 USD/百万token计保守上界；它不利用供应商缓存折扣冒充精确实付。报价有时效检查，未来执行需重新核对，不用历史价格证据重开已消费实验。

7.2 Watchdog与有限主动性

独立Watchdog只使用专用受限本机HTTP令牌读取状态、提交RecoveryRequest，不加载完整模型/数据库/GitHub凭据，不直接控制Run或批准Action。Engine依据当前PG事实重算信号，人工决定前再次检查是否已过期。

心跳、积压、依赖健康与等待时间形成确定性观察。默认observe；有限auto策略需要管理员对准确策略hash激活。只读影子Run有独立预算，不能生成发布Action或可信记忆。巡检成功不等于业务有进展。

7.3 独立Linux/systemd虚拟机

原云容器没有systemd PID1，不能当作宿主部署证据。用户选择独立VM后，实际使用Debian12/Linux6.1、3GiB、PG16/pgvector、Redis、Docker overlay2与独立mgar/watchdog用户，无NIC和模型/GitHub凭据。

验收包含两次整个QEMU SIGKILL、正常重启、四个不同boot_id、PG WAL恢复、已提交保留/未提交回滚、CAS/去重/费用记录保留、旧epoch拒绝，以及第二数据库的角色与只读Reader恢复。证据支持整虚拟节点恢复；物理存储掉电、用户生产宿主及多节点HA未验证。

相邻V2仅在明确授权下维护P7-06J测试夹具时钟，保留历史价格和623个历史文件哈希；相关688项Go、453项Python及15子测试通过。该维护不重开V2付费阶段，也不改变V3模型分数。

依据：Watchdog ADR、R6设计、宿主完整档案。

8. 实验设计与全部主要结果

8.1 三种验证模式

模式	实际运行	可以支持的结论
工程/受控模型	真实PG/Redis/Checkpoint/HTTP/MCP/Go；模型和远端显式替身	协议、事务、边界、恢复和拒绝行为
真实本地组件	本地预训练检索、学习重排、SQL、编译与VM	被测组件在注册资料/环境上的结果
真实付费实验	官方DeepSeek、真实工具/公开GitHub代码、合成业务数据	冻结任务上的业务效果、调用、费用及失败

真实工具不意味着真实商家生产数据。机械引用通过也不等于解释充分。报告将三种模式分别陈述，避免把工程PASS替代业务PASS。

8.2 R1、R4、R5

阶段	真实结果	解释
R1	2次模型调用，一条结果评论；模型落库/远端回执SIGKILL恢复	首次结构错误未发布，第二次成功
R3	1次限定真实Router，合成场景、已知结果恢复	累计模型调用到3；非生产语义路由评测
R4	3正常+2不足/越权；多专家/单Agent首轮各4/5	共20次首轮调用，恢复另3次；多专家一次恢复后有完整五例通过记录，首轮失败不改
R5	原3次模型补丁均FAIL；第一份已结算结果仅规范化hunk后通过公开/28隐藏测试，并创建Draft PR #2	恢复新增模型调用0；原始格式/定位失败不变

R4首轮多专家15次调用/US$0.013888、单Agent5次/US$0.007510，平均耗时7.5364秒与4.3670秒；该小样本没有证明多专家更好。案例顺序固定、缓存与网络未分离，耗时只作描述。独立不足/撤权检查可零模型完成。

8.3 R6题集、独立Oracle与修复演进

30个冻结任务为10 QA、10跨源、5纯函数修复、5不足/越权；A单Agent、B固定专家、C按需专家，共90项分配。共用模型、来源和价格，最多每项3次模型、16个逻辑工具及180秒；确定性取证计划相同，比较的是推理协作，不是自由工具规划。

数值由独立Python Oracle、引用原文及实际隔离Go测试判断，无模型自评。题集开发者可见且参与修复回归；隐藏测试保护不等于整个任务集为未知盲测。

冻结批次	结果	本批调用	峰值保守USD
原始完整v2	46PASS / 44FAIL / 90	195	0.087980
中间v3	23PASS / 12FAIL / 55NOT_RUN	68	0.037047
完整v4	74PASS / 16FAIL / 90	176	0.084336
v5请求拒绝	1FAIL / 89NOT_RUN	3	0.000518
最新完整v6	87PASS / 3FAIL / 90	162	0.060887

v4虽C达到24/30，但正常19/25未达到20/25，仍FAIL。v6 C达到原冻结门槛：总计至少24/30、正常20/25、负例5/5、引用100%；原三项失败继续保留，没有调低门槛。

v6方案	全部	正常	负例正确	修复/5	模型调用	保守USD	P50 / P95秒
A 单Agent	30/30	25/25	5/5	5/5	27	0.013151	1.6828 / 27.8045
B 固定专家	28/30	23/25	5/5	3/5	75	0.025058	3.6810 / 29.4982
C 按需专家	29/30	24/25	5/5	5/5	60	0.022678	3.6626 / 29.8061

机械引用有效率各100%；有检索统计的每臂23项中Recall@5为22/23。此前R4本地12个中文改写问题为11/12，语料和分母不同，不合并比较。v6 A的成功率95%区间为[0.8865,1.0]、C为[0.8333,0.9941]，配对比较C/A及C/B的精确McNemar p均为1.0，未建立多Agent优势。消融NOT_RUN。

依据：v6统计、失败分析、全历史档案。

8.4 D/E/F协调首轮与E/F复验

D使用冻结人工操作表，延迟不包含人类思考时间；E每条获准非重复事件调用Router；F订阅直达，冷事件按预定阶段合批。固定真实LangGraph R2 Worker、模型、来源和并发2，使用源读取屏障使两条后续消息在模型调查前进入同一任务。

v1为两重复×来源缓存cold/warm×D/E/F，共12次；每臂正常8、负例12、路由36。每次10次物理投递/9个逻辑事件，包含一个重复。cold/warm仅控制Worker来源Redis键，PG/供应商缓存不强制清冷；模型temperature/seed使用默认值，随机种子仅控制顺序。

版本/方案	正常	负例	路由	Router/Worker调用	全部调用	保守USD
v1 D	7/8	12/12	36/36	0/8	8	0.001306

版本/方案	正常	负例	路由	Router/Worker调用	全部调用	保守USD
v1 E	1/8	12/12	15/36	32/1	33	0.003233
v1 F	4/8	12/12	24/36	12/4	16	0.001936
v2 E	7/8	12/12	36/36	32/8	40	0.003494
v2 F	8/8	12/12	36/36	12/8	20	0.002227

v2仅重测E/F共8次，合计60次模型调用、峰值保守US$0.005721；D未同期重跑，旧D7/8是历史参照。首轮11项非法初始提案引起22项后续路由失败；v2改为单合法候选、同事务重核，72个逻辑事件全部按预期处理。

v2 F相对E少20次Router：16次来自已订阅后续消息直达，4次来自双事件合批，32→12减少62.5%。v1的部分“少调用”来自失败启动后的输入阻塞，不能算作效率提升。v2每方案Worker均8次，所以总调用40→20；这一结果限定于本负载。

v2事件分派P50/P95为E 1.299815/2.829654秒，F 0.013039/1.435371秒。内部报告耗时为E 8.375863/9.355599秒，F 2.396738/3.472157秒；E内部报告包括一项独立业务FAIL，因此不能全部称为业务成功耗时。

F在有效真实响应已结算、事件应用前SIGKILL；显式恢复复用同一结果，新增调用/费用0，旧epoch心跳拒绝。真实44次Router均首次有效，纠正路径没有在本轮真实触发；第二次有效响应后SIGKILL只在受控模型工程测试中验证。

依据：v1完整报告、v2完整报告、恢复收据。

8.5 费用与累计口径

结案节点	累计物理调用	累计峰值保守USD
R1/R3后	3	0.002456
R4后	26	0.027025
R5后	29	0.028549
R6 v6后	633	0.299317
D/E/F v1后	690	0.305792
E/F v2后	750	0.311513

最近结案未知/预占0。累计含失败、HTTP拒绝、历史路由和所有修复批次；不是最新162次或60次实验的单独成绩。只读复用已结算模型结果不增加物理请求；尚未使用的旧授权额度不转移。该表复述公开结案账本，本轮文档整理不新增费用。

9. 困难、错误与对应解决过程

9.1 输出与工具协议错误

表现	原因	修改与验证	当前结论
R1首个结构化响应不合约	模型输出不能仅靠提示保证结构	严格DTO校验，失败不发布；第二次有效响应及真实评论闭环验收	原失败保留
GitHub源码读取结构不匹配	实际MCP返回嵌入资源，客户端假定文本形态	按真实资源结构解析并核验commit/blob/hash	已实现并用于R4真实实验
R4 Repo专家返回空claims、额度耗尽	给单来源专家分配了依赖SQL的跨源问题	将专家子问题限制为本来源引文，综合步骤负责跨源答案	有界恢复通过；首轮仍各4/5
R5三次原始diff格式/定位失败	模型同时承担业务修复和diff框架生成	先仅重算hunk计数；后续新协议仅生成函数体，可信框架渲染diff	原FAIL不重写；语义仍由测试判断
v6 C cross-05仍有根输出契约错误	真实模型返回额外/不符结构，有限调用未恢复正确答案	保存原响应和明确错误，不把safe insufficient当正确正常答案	OPEN，原FAIL

R5仅行数恢复的具体变化为`@@ -7,8 +7,16 @@`→`@@ -7,9 +7,16 @@`，未改代码、路径和起始位置。恢复运行独立记录，不能冒充模型首次补丁成功。依据：R4、R5、v6残余复现。

9.2 数值、引用与修复语义错误

表现	原因	修改与验证	当前结论
cross-07 C输出48.00，实际SQL为20.00	让模型自行算数，缺实际观察末端不变量	实际行与SQL count/sum/min交叉验证，Decimal计算；覆盖非正金额和乱序事件	已在新冻结回归验证
同一SQL数据补查后被当成冲突	时间戳/回执hash混入语义证据	稳定查询/行/指标供模型，易变观察回执仅进CAS	内容一致性与独立回执测试通过
专家摘要格式错误导致主流程终止	未区分已知格式失效和来源/费用未知	只丢弃并审计已知坏摘要，主Agent仍读原始来源；unknown照常停止	工程与真实回归记录保留

表现	原因	修改与验证	当前结论
引用拼接、前缀丢失	模型自由复制/改写引文	R6用quote_id绑定实际原文；E/F固定Worker未同步改变	E/F v2 E仍有1项完整行FAIL
B repair-02/03漏paid过滤	补丁语法与公开案例可过，业务逻辑遗漏状态约束	原独立隐藏测试拒绝，保存两份候选、测试回执与失败	OPEN，两项原FAIL
v1 D statement/quote不一致	引用句有Observation前缀而statement省略	原Verifier拒绝，报告保留；P0提出统一完整单元契约	旧FAIL保留，P0仅设计

v2 E r0/warm e01的statement和quote都为`The documented cache TTL is 90 seconds.`，来源完整行是`Observation: The documented cache TTL is 90 seconds.`。原Verifier接受相同来源子串，Run为succeeded；独立Oracle要求完整行，判FAIL。路由和两条后续输入均正确，不能归因于Router。修复协调器时保持Worker不变，避免混入另一变量。

依据：数值复现、问题登记、E剩余失败。

9.3 JSON模式HTTP400与未知计费

v5新增主Agent提示漏写JSON，而供应商JSON-object模式要求消息含JSON。两条专家请求正常，主请求收到HTTP400且无usage；首题累计3次调用后停止，保留1FAIL/89NOT_RUN和US$0.006144预占。HTTP400本身不能证明免费。

第一次收到的账单ZIP内部是11月3日，不能核对11月5日请求。之后完整11月5日15:00–16:00账单的2次成功请求、输入608、输出279与两个本地专家回执逐项相等，可确认该明确拒绝没有额外计费。财务结算为0额外美元，不编造其token，不把CNY单价当USD，不退调用次数；两个成功请求仍保守计US$0.000518。

修复在主提示、付费专家分支之前、每次complete预占之前及真实preflight分别检查JSON前置约束。核账路径仅接受一个已停止任务的明确invalid-request拒绝及完整相等账单，缺记录或混合未知则失败关闭。新协议另冻结v6，不继续改写旧v5。

另一次原始R6响应丢失涉及同小时13次请求中的11个已知与2个未知；差额输入613、输出322 token，按冻结美元峰值和取整余量核账US$0.000572。逐请求token未获知，分配值只作聚合记账；响应丢失仍为业务失败，没有重新请求。

依据：JSON事故全过程、原核账摘要。

9.4 协调器的初始错误与级联失败

表现	原因	修改与验证
v1 E7项/F4项初始错误，22项后续失败	自由action/UUID允许deliver/null或跨Issue目标；启动失败后没有primary	公开PG快照生成合法候选，模型只选编号；固定Worker/Oracle不变，新版E/F路由各36/36
guard与ingest存在事务间隙	检查和写入跨事务，期间可能变化	原持锁连接同一SQL-only外层事务重核Run/epoch/revision/actor，异常整体回滚

表现	原因	修改与验证
已结算格式错误直接结束	缺少严格有界纠正路径	每批最多两个独立单调用slot，只对已结算格式/候选错误纠正；unknown/provider/budget/fencing不纠正
原恢复收据response_hash为null	读取了usage_calls不存在的列	从原生model_response_recorded.safe_payload.content_hash取值，并在事务外核对CAS；旧空值收据保留
97项测试通过但验收FAIL	验收期间源码改变，源指纹不一致	保存无效首次记录，稳定源码后重跑98项，通过后再冻结真实实验

以上纠正使用新的独立授权与预算组，不借用v1剩余11次。真实v2没有触发格式纠正，第二次响应后的恢复证据来自受控测试，不能夸称真实纠正成功率100%。依据：完整修复档案。

9.5 基础设施、监督和报告工具错误

问题	原因	解决与保留范围
270次评测组初始化被数据库拒绝	原通用authorization_budgets envelope上限100	追加迁移0017独立benchmark_budgets；旧上限/历史账目不改，零调用setup失败保留
OOM中断与续跑	本地进程被系统终止；18项/42次调用已结算	封存完成结果，用独立监督逐项续跑；已开始未完成任务记基础设施失败，组预算不重置
完成90项后仍报WORKER_LIMIT	有限循环只在每轮开头检查完成	循环结束后检查持久all-complete状态；不重跑已完成实验
报告脚本累计不符	仅数usage_calls漏历史router_calls；把manifest hash误当budget hash	用权威repository cost API和grant→budget join；只改读取器，不二次结算
证据构建器字段/格式假设错误	使用passed代替success；把Markdown报告当JSON	更正只读构建器；无模型调用、无业务重评，首次构建失败日志保留
管理环境恢复与临时文件丢失	工具曾offline、临时依赖路径失效，PG卷仍在	先核对原进程/账本，按uv.lock恢复环境，再复验；不因连接中断重发未知请求
systemd验收没有实际宿主	原云容器PID1并非systemd	新建用户指定的独立Linux VM，真实部署/强杀/重启/备份恢复；不扩张为生产HA

问题	原因	解决与保留范围
VM中ROM/编码/权限/overlay/编译超时	环境与可信沙箱前提未完全一致	修复ROM路径、UTF8、属主、Docker/PATH、匹配内核模块、Go缓存；原超时和权限失败留档
串口ANSI/背压导致监督误判	解析器和等待阶段未持续消费输出	修正解析与串口读取，封存已通过客体结果；不放宽沙箱45秒和资源限制
Reader恢复被误判	探针绕过正式DataReader会话参数	用正式Reader并额外关闭会话只读验证角色仍不能INSERT；失败恢复库保留
V2价格夹具时钟过期	历史测试引用时间与当前freshness判断不一致	仅授权测试时钟维护，历史报价不改；正式付费入口继续拒绝过期/未来证据
报告公开推送曾被审批拒绝	旧授权未具体覆盖详细业务报告/回执的公开范围	用户明确允许修复后公开报告与脱敏证据，再推送并核对远端；没有绕过拒绝

这组问题说明评测器、账本导出、监督器和部署工具也需要验证。报告修正、环境恢复和业务模型改进分别记录，不能用修正统计脚本改变原始模型失败。

依据：R6问题登记、VM失败历史、E/F工程首次记录。

10. 仅完成设计的两项P0

10.1 “研巡”电商工单闭环

拟面向值班开发/技术支持，覆盖重复paid事件、pending/cancelled混入、整单refunded排除三个注册场景。复用现有orders单表和Go纯函数，不扩展跨表退款流水、通用SQL或任意仓库修复。

Case关联原Thread，调查Run保持只读；结束并释放primary后，凭独立修复许可创建新R5 Ticket/Run。交接绑定Case/spec/input/revision、调查结果hash、知识/数据/代码版本和预算。修复Run重新读取/登记自己的证据，不伪装继承前Run读取权限。

P0-A设计了Case输入、六个拟新增API、工作台时间线、关联表草案及重复/追加/取消/未知处理。当前新Case接口和数据表均未实现。普通调查消息走Mailbox，R5补丁编辑走原修复协议；业务口径变化要使旧提案失效，不能把普通聊天强行投给不支持intake的图。

10.2 统一业务结果判定

拟新增不可变business_result，将执行、业务、审批、交付分开。业务结果为passed/failed/needs_input/denied/unknown；未评估单列。检查范围为scope、evidence、contract、acceptance，模型不能自己填最终判定。

完整引用由本Run实际来源目录绑定；金额由typed cell与Decimal回执重算。修复提案需公开/独立测试均通过；发布仍走原审批/Outbox。新输入或撤权通过当前适用性阻断旧结果，不改写旧PASS/FAIL。页面和写接口使用同一判定规则，写操作再次重查服务器授权。

设计核对现有源码后发现，commit_report即使传stored_report_hash也会读CAS，Repairs.create也先准备源码/CAS。未来需要拆成事务外prepare和Engine内部SQL-only提交段，保持原入口兼容，才能原子登记业务判定与原Run/Action状态；不能简单在现有入口外包一个事务。

10.3 设计检查与实施状态

交付包括三份JSON Schema、四个任务样例（含report-only变体）、九个结果样例、20个展示状态、三个数据集、五个业务场景和22项工程验收要求。11个故意构造的错误样例被拒绝，数值与状态守卫独立检查通过，424个受保护运行/历史文件未改。

设计阶段更正了发布状态被“执行中”遮住、补丁编辑后旧结果未立即失效、report目标与spec hash绑定不一致等问题。设计检查通过不替代实际运行。两项P0仍为DESIGN_COMPLETE / implementation NOT_STARTED / engineering和live NOT_RUN。

未来验收提案为3正常+2不足/撤权，拟最多18次模型、峰值US$0.055296、3个获批Draft PR；没有生成新授权或转移旧额度，本轮未执行。其他盲测、消融、复杂Router、多文件修复、压力长跑、团队登录和生产HA均按用户范围不开展。

依据：P0设计入口、闭环、统一结果、设计检查。

11. 复现、验证及源码导航

11.1 安装与本地模式

使用Git、Make、uv、Python3.12和Docker Compose V2；Windows/WSL先按本地运行指南配置。逐步确认命令成功后再继续：

```
git clone https://github.com/Loz888/MAGR-v3.git
cd MAGR-v3/v3
uv python install 3.12
make setup
make deps-up
make migrate
make doctor
make dev
```

setup按uv.lock安装，并仅生成缺失的0600本地配置。默认只监听127.0.0.1:18080，fixture模式不付费、不向GitHub发布。工作台令牌从本机.env读取，不上传。云工作区路径不是用户本机安装位置。

```
make lint
make typecheck
make verify TASK=V31-R6-COORD-REPAIR
```

注册验收保存实际退出码、JUnit、源摘要和原始日志，拒绝缺测试、零收集、跳过、超时和验证中源码变化。最后命令运行真实基础组件及受控模型，原98项成绩属于既有快照，本报告整理没有重新执行它。不同阶段完整/专项数量不能相加，也不把旧321项或295项描述成本轮重跑。

R4本地检索和R5沙箱需要额外模型/镜像准备，见各runbook。真实执行需要匹配来源、模型、预算、到期和外发范围的许可；已有manifest目录禁止静默覆盖，不能复制旧许可重开模型或GitHub写。历史脚本可能绑定当时的账本前序，干净克隆不应伪造旧账目。

11.2 模块与关键实现

模块	代码入口	职责
全局协调	coordination/engine.py	事件、Run、控制、报告、调用账本与统一业务写入
输入与图	graph/	Mailbox、checkpoint、长读取与专家图
产品路由	routing/	冷事件批次、候选、纠正及授权
跨源工具	agents/ · mcp/	数据角色、专家、MCP适配与引用验证

模块	代码入口	职责
知识与RAG	knowledge/ · rag/	版本化入库、混合检索、重排和权限过滤
修复	repair/	snapshot、函数体/diff、AST、沙箱和发布子步骤
外部效果	effects/	Action/Outbox/Dispatcher、回执和只读对账
恢复与主动性	recovery/ · proactivity/	Watchdog、心跳、建议与只读策略
原真实评测	benchmark/	冻结、执行、独立Oracle、核账和统计
协调对照	coordination_eval/	D/E/F实验适配器、共享预算、Journal和独立判定
页面与API	api.py · web/	原本地工作台、SSE与统一入口
部署	deploy/ · migrations/	锁定基础服务、systemd/VM资产和17个产品迁移

12. 剩余限制与工程经验

12.1 保留的失败与边界

原v6 C cross-05输出契约、B repair-02/03业务过滤错误继续FAIL；E/F v2 E完整行引用失败、v1 D引用契约失败和全部早期批次原样保留。后续设计提出改进路径，并没有修复或重新判定这些历史结果。

题集规模小、开发者可见、多轮调试；只有固定来源与工具计划，缺独立盲测、消融及大规模真实业务样本。单Agent在v6更好，E/F的单候选负载也未证明复杂语义协调价值。生产多租户、通用SQL、任意代码修复、多节点HA没有本报告中的验收证据。

12.2 可迁移的设计经验

1. 把权限、状态、版本和外部写权放在可信代码与PG约束中，模型只提出有界内容或候选。
2. 让模型选择实际来源单元或生成函数体，可信代码承担精确引用和diff框架；业务逻辑仍由独立测试判断。
3. 把输入快照、图状态、业务结果和远端对象的不同提交边界写清楚，使用幂等、epoch和对账处理故障。
4. 费用未知是财务与执行事实，保留预占和失败，核账不创造答案，也不退回请求次数。
5. 用相同冻结条件作对照，分别报告工程、业务、引用、修复测试、延迟和成本；保留不利结果。
6. 评测/部署/报告工具自身也可能出错，改读取器不能改模型成绩，源码指纹变化必须让验收失效。
7. 产品页面应表达当前可操作状态；“执行成功”“业务通过”“已审批”“已交付”应分别可追溯。

用户已限定本轮后续范围为两项P0设计，其余改进暂停。本报告不将“可能的未来工作”列为已实现能力或承诺的新实验。

13. 主要证据

编号	可核对材料	用途
E01	架构ADR目录	历史设计、取舍、授权与状态边界
E02	R1真实摘要	首个真实模型/评论及两类SIGKILL
E03	R4真实实验	三源调查与单Agent首轮对照
E04	R5真实报告	原补丁失败、受限恢复、Draft PR #2
E05	v6冻结manifest	来源、模型、输入与预算冻结
E06	v6统计 · 失败	87/90、三项FAIL、配对统计
E07	R6问题登记	数值、协议、权限、修复及监督错误
E08	JSON事故	HTTP400及精确账单核对
E09	宿主验收	VM、恢复及V2测试维护
E10	D/E/F v1	12次首轮实测与全部失败
E11	E/F v2 · 修复	候选契约、60次实测、残余Worker问题
E12	最新费用	累计750次/US$0.311513及未知/预占
E13	P0设计 · 检查	仅设计成果、Schema、样例和实施边界
E14	事实索引 · 文档检查	本报告数值与来源hash、文档验证范围

公开材料包含合成输入、输出、脱敏回执与不可变来源索引。原始模型CAS、完整私有授权、密钥/DSN、账单及数据库/角色恢复备份留在本地私有材料；公开报告不携带这些凭据。